


Armazenamento de disco, fundamentos de estruturas de arquivo, hashing e arquiteturas de Armazenamento modernas



Introdução

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- A mídia de armazenamento de computador forma uma hierarquia de armazenamento que inclui três categorias principais:

1. Armazenamento primário.

2. Armazenamento secundário.

3. Armazenamento terciário.

- No nível de armazenamento primário, a hierarquia de memória inclui, no extremo mais caro, a **memória cache**, que é uma RAM estática.
- No nível de armazenamento secundário e terciário, a hierarquia inclui discos magnéticos, bem como **armazenamento em massa** na forma de dispositivos de CD-

Introdução

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- Os programas residem e são executados na DRAM.
- As **memórias flash** são de alta densidade e alto desempenho e usam a tecnologia EEPROM.
- As memórias flash podem ser de dois tipos, denominados NAND e NOR, com base no tipo de circuito lógico utilizado.
- A forma mais popular de armazenamento óptico removível são os CDs e os DVDs.
- As **fitas magnéticas** são usadas para arquivamento e armazenamento de backup dos dados.
- Os **jukeboxes de fita** estão se tornando populares como armazenamento terciário, para manter terabytes de dados.

Introdução

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- Tipos de armazenamento com capacidade, tempo de acesso, largura de banda (velocidade de transferência) máxima e custo da commodity:

Tipo	Capacidade*	Tempo de acesso	Largura de banda máxima	Preços de commodity (2014)**
Memória principal – RAM	4 GB–1 TB	30 ns	35 GB/s	US\$ 100–US\$ 20K
Memória flash – SSD	64 GB–1 TB	50 µs	750 MB/s	US\$ 50–US\$ 600
Memória flash – pen drive	4 GB–512 GB	100 µs	50 MB/s	US\$ 2–US\$ 200
Disco magnético	400 GB–8 TB	10 ms	200 MB/s	US\$ 70–US\$ 500
Armazenamento óptico	50 GB–100 GB	180 ms	72 MB/s	US\$ 100
Fita magnética	2,5 TB–8,5 TB	10 s–80 s	40–250 MB/s	US\$ 2,5K–US\$ 30K
Jukebox de fita	25 TB – 2.100.000 TB	10 s–80 s	250 MB/s–1,2 PB/s	US\$ 3K–US\$ 1M+

Introdução

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- As técnicas utilizadas para armazenar grande quantidade de dados estruturados em disco são importantes para os projetistas de banco de dados, para o DBA e para implementadores de um SGBD.
- O processo de **projeto físico de banco de dados** envolve a escolha das técnicas de organização de dados em particular que mais se ajustam a determinados requisitos da aplicação entre as opções.
- Algumas organizações de arquivo primárias, como B-trees, usam estruturas em árvore.
- Uma organização secundária ou estrutura de acesso auxiliar permite acesso eficiente aos registros do arquivo com base em campos alternativos, além dos que foram usados para a organização de arquivo primário.

Descrição de hardware dos dispositivos de disco

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- Os discos magnéticos são usados para armazenar grande quantidade de dados.
- O dispositivo que mantém os discos é chamado de **unidade de disco rígido**, ou **HDD**.
- A **capacidade** de um disco é o número de bytes que ele pode armazenar, que em geral é muito grande.
- Independentemente de sua capacidade, todos os discos são feitos de um material magnético na forma de um disco circular fino.
- Um disco é de **face simples** se armazenar informações apenas em uma de suas superfícies, e de **face dupla** se as duas superfícies forem usadas.


Descrição de hardware dos dispositivos de disco

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- Um disco de face simples com hardware de leitura/gravação.
Um volume de discos com hardware de leitura/gravação:




Descrição de hardware dos dispositivos de disco

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- Diferentes organizações de setor no disco. Setores se estendendo por um ângulo fixo:




Descrição de hardware dos dispositivos de disco

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- Diferentes organizações de setor no disco. Setores mantendo uma densidade de gravação uniforme:



Descrição de hardware dos dispositivos de disco

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- A transferência de dados entre a memória principal e o disco ocorre em unidades de blocos de disco.
- O **endereço de hardware** de um bloco é fornecido ao hardware de E/S (entrada/saída) do disco.
- O **endereço de um buffer** também é fornecido.
- Para um comando de leitura, o bloco de disco é copiado para o buffer.
- Para um comando de gravação, o conteúdo do buffer é copiado para o bloco de disco.
- Às vezes, vários blocos contíguos podem ser transferidos como uma unidade, denominada **cluster**.

Descrição de hardware dos dispositivos de disco

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- Um **controlador de disco**, normalmente embutido na unidade de disco, controla a unidade de disco e a interliga ao sistema de computação.
- O controlador aceita comandos de E/S de alto nível e age de maneira apropriada para posicionar o braço e fazer que aconteça a ação de leitura/gravação.
- Para transferir um bloco de disco, dado seu endereço, o controlador de disco primeiro deve posicionar mecanicamente a cabeça de leitura/gravação na trilha correta.
- O tempo exigido para fazer isso é chamado **tempo de busca**.
- Os tempos de busca típicos são de 5 a 10 ms em desktops e de 3 a 8 ms em servidores.

Descrição de hardware dos dispositivos de disco

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- Técnicas comumente usadas para tornar o acesso aos dados mais eficiente nas unidades de disco rígido:
 1. Buffering de dados
 2. Organização adequada dos dados no disco
 3. Leitura de dados antes de serem solicitados
 4. Escalonamento adequado de solicitações de E/S
 5. Uso de discos de registro para manter as escritas temporariamente
 6. Uso de SSDs ou de memória flash para fins de recuperação

Descrição de hardware dos dispositivos de disco

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

Armazenamento em dispositivo no estado sólido (SSD)

- O componente principal de um SSD é um controlador e um conjunto de cartões de memória flash interconectados.
- Não há restrição na colocação de dados em uma SSD, pois qualquer endereço é diretamente endereçável.
- Em SSDs, os dados são gravados em diferentes células NAND para atingir o nivelamento de desgaste, o que prolonga a vida útil da SSD.
- O principal problema que impede uma adoção em larga escala de SSDs hoje é seu custo proibitivo, que costuma ser de cerca de 70 a 80 centavos de dólar por GB, ao contrário dos 15 a 20 centavos por GB para HDDs.

Descrição de hardware dos dispositivos de disco

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

Dispositivos de armazenamento de fita magnética

- As fitas magnéticas são dispositivos de acesso sequencial.
- Os dados são armazenados em bobinas de fita magnética de alta capacidade, semelhantes às fitas de áudio ou vídeo.
- Uma unidade de fita precisa ler os dados ou gravá-los em uma **bobina de fita**.
- A principal característica de uma fita é seu requisito de que acessemos os blocos de dados em **ordem sequencial**.
- As fitas têm uma função muito importante — **backup** do banco de dados.

Buffering de blocos

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- A figura a seguir ilustra como dois processos podem prosseguir em paralelo.
- Os processos A e B estão rodando simultaneamente em um padrão intervalado, em que os processos C e D estão rodando simultaneamente em um padrão paralelo.
- Quando uma única CPU controla vários processos, a execução paralela não é possível.
- Contudo, os processos ainda podem ser executados de maneira simultânea de uma forma intervalada.
- O buffering é mais útil quando os processos podem ser executados simultaneamente em um padrão paralelo.

Buffering de blocos


SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

Concorrência intervalada
das operações A e B

Execução paralela das
operações C e D




Buffering de blocos

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- A figura abaixo ilustra como a leitura e o processamento podem prosseguir em paralelo quando o tempo exigido para processar um bloco de disco na memória é menor que o tempo exigido para ler o bloco seguinte e preencher um buffer:



Buffering de blocos

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- Existem dois tipos de gerenciadores de buffer:
 1. o primeiro controla a memória principal diretamente, como na maioria dos SGBDRs,
 2. o segundo aloca buffers na memória virtual, o que permite que o controle seja transferido para o sistema operacional (SO).
- O gerenciador de buffer mantém dois tipos de informações disponíveis sobre cada página no pool de buffers:
 1. Um contador de visitas
 2. Um bit de modificação

Buffering de blocos

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

▪ Estratégias de substituição de buffer:

1. **Usado menos recentemente (LRU)**: a estratégia aqui é remover a página que não foi usada (lida ou escrita) há mais tempo.
2. **Política de relógio**: esta é uma variante de rodízio da política LRU.
3. **Primeiro a entrar, primeiro a sair (FIFO)**: com essa política, quando um buffer é solicitado, o que foi ocupado há mais tempo por uma página é usado para a substituição.
4. Existem algumas outras estratégias de substituição, como **MRU (usado mais recentemente)**, que funcionam bem para certos tipos de transações de banco de dados, por exemplo, quando um bloco usado mais recentemente não é mais necessário até que sejam processados todos os blocos restantes na relação.

Gravando registros de arquivo no disco

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- Os dados costumam ser armazenados na forma de **registros**.
- Cada registro contém uma coleção de valores ou itens de dados relacionados, em que cada valor é formado por um ou mais bytes e corresponde a um **campo** em particular do registro.
- Os registros normalmente descrevem entidades e seus atributos.
- Um **tipo de dado**, associado a cada campo, especifica os tipos de valores que um campo pode assumir.
- Um **arquivo** é uma sequência de registros.
- Se cada registro no arquivo tem exatamente o mesmo tamanho (em bytes), o arquivo é considerado composto de **registros de tamanho fixo**.

Gravando registros de arquivo no disco

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- Se diferentes registros no arquivo possuem diversos tamanhos, o arquivo é considerado composto de **registros de tamanho variável**.
- Para campos de tamanho variável, cada registro tem um valor para cada campo, mas não sabemos o tamanho exato de alguns valores de campo.
- Um campo repetitivo precisa de um caractere separador para afastar os valores repetitivos do campo e outro caractere separador para indicar o término do campo.
- Finalmente, para um arquivo que inclui registros de diferentes tipos, cada registro é precedido por um indicador de **tipo de registro**.

Gravando registros de arquivo no disco

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- Os registros de um arquivo precisam ser alocados a blocos de disco, porque um bloco é a unidade de transferência de dados entre o disco e a memória.
- Quando o tamanho do bloco é maior que o tamanho do registro, cada bloco terá diversos registros, embora alguns arquivos possam ter registros excepcionalmente grandes que não cabem em um bloco.
- Um **ponteiro** no final do primeiro bloco aponta para o bloco que contém o restante do registro, caso não seja o próximo bloco consecutivo no disco.
- Essa organização é chamada de **espalhada** porque os registros podem se espalhar por mais de um bloco.

Gravando registros de arquivo no disco

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- Sempre que um registro é maior que um bloco, temos de usar uma organização espalhada.
- Se os registros não puderem atravessar os limites de bloco, a organização é chamada de **não espalhada**.
- Na **alocação contígua**, os blocos de arquivo são alocados a blocos de disco consecutivos.
- Na **alocação ligada**, cada bloco de arquivo contém um ponteiro para o próximo bloco.
- Um **cabeçalho de arquivo** ou **descriptor de arquivo** contém informações sobre um arquivo, que são exigidas pelos programas do sistema que acessam os registros do arquivo.

Operações em arquivos

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- Operações em arquivos costumam ser agrupadas em:

1. operações de recuperação e

2. operações de atualização.

- Normalmente, programas de alto nível, como programas de software de SGBD, acessam registros usando esses comandos, de modo que às vezes nos referimos a variáveis de programa nas descrições a seguir:
- Open
- Reset
- Find (ou Locate)
- Read (ou Get).
- FindNext

Operações em arquivos

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- Delete
- Modify
- Insert
- Close
- Scan
- FindAll
- Find (ou Locate) n
- FindOrdered
- Reorganize

Arquivos de registros desordenados (arquivos de heap)

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- Neste tipo de organização mais simples e mais básico, os registros são arquivados na ordem em que são inseridos, de modo que novos registros são inseridos ao final do arquivo.
- Essa organização é chamada **arquivo de heap** ou **pilha**.
- A inserção de um novo registro é muito eficiente.
- O último bloco de disco do arquivo é copiado para um buffer, o novo registro é acrescentado e o bloco é então regravado de volta no disco.
- Para excluir um registro, um programa deve primeiro encontrar seu bloco, copiá-lo para um buffer, excluir o registro do buffer e, finalmente, regravar o bloco de volta ao disco.

Arquivos de registros ordenados (arquivos classificados)

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- Podemos ordenar fisicamente os registros de um arquivo no disco com base nos valores de um de seus campos — chamado de **campo de ordenação**.
- Isso leva a um **arquivo ordenado** ou **sequencial**.
- Se o campo de ordenação também for um campo-chave do arquivo, então o campo é chamado de **chave de ordenação para o arquivo**.
- Para inserir um registro, temos de encontrar sua posição correta no arquivo, com base no valor de seu campo de ordenação, e depois criar espaço no arquivo para inserir o registro nessa posição.
- Uma opção para tornar a inserção mais eficiente é manter algum espaço não usado em cada bloco para novos registros.

Arquivos de registros ordenados (arquivos classificados)

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- A modificação do valor de um campo de registro depende de dois fatores:
 1. a condição de pesquisa para localizar o registro e
 2. o campo a ser modificado.
- Se a condição de pesquisa envolver o campo da chave de ordenação, podemos localizar o registro com uma pesquisa binária; caso contrário, temos de realizar uma pesquisa linear.
- Um campo não ordenado pode ser modificado ao alterar o registro e regravá-lo no mesmo local físico no disco.
- A modificação do campo de ordenação significa que o registro pode alterar sua posição no arquivo.

Técnicas de hashing

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- Outro tipo de organização de arquivo principal é baseado no hashing, que oferece acesso muito rápido aos registros sob certas condições de pesquisa.
- Essa organização costuma ser chamada de **arquivo de hash**.
- Para arquivos internos, o hashing normalmente é implementado como uma **tabela de hash** por meio do uso de um vetor de registros.
- Uma técnica, chamada **desdobramento**, consiste em aplicar uma função aritmética, como a adição, ou uma função lógica, como o *or exclusivo*, a diferentes partes do valor do campo de hash para calcular o endereço de hash.

Técnicas de hashing

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- Uma colisão ocorre quando o valor do campo de hash de um registro que está sendo inserido é calculado como um endereço que já contém um registro diferente.
- Nessa situação, temos de inserir o novo registro em alguma outra posição, pois o endereço de hash está ocupado.
- O processo de localizar outra posição é chamado de resolução de colisão.
- Existem métodos para resolução de colisão, incluindo os seguintes:
 1. Endereçamento aberto
 2. Encadeamento
 3. Hashing múltiplo

Técnicas de hashing

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

- O hashing para arquivos de disco é chamado de **hashing externo**.
- Para se ajustar às características do armazenamento de disco, o espaço de endereços de destino é feito em **buckets**, cada um mantendo vários registros.
- O hashing oferece o acesso mais rápido possível para recuperar um registro qualquer dado o valor de seu campo de hash.
- Ao usar o hashing externo, a busca por um registro, dado um valor de algum campo diferente do campo de hash, é tão dispendiosa quanto no caso de um arquivo desordenado.
- A modificação do valor de campo de um registro específico depende de dois fatores: da condição de pesquisa para localizar esse registro específico e do campo a ser modificado.


Técnicas de hashing

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

Hashing extensível




Técnicas de hashing

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

Hashing dinâmico



Outras organizações de arquivo primárias

SISTEMAS DE BANCO DE DADOS

7ª edição

ELMASRI • NAVATHE

Arquivos de registros mistos

- Para distinguir os registros em um arquivo misto, cada registro tem — além de seus valores de campo — um campo de **tipo de registro**, que especifica esse item.
- Esse costuma ser o primeiro campo em cada registro e é usado pelo software do sistema para determinar o tipo de registro que ele está prestes a processar.
- Usando a informação do catálogo, o SGBD pode determinar os campos desse tipo de registro e seus tamanhos, a fim de interpretar os valores de dados nele.