Aquisição de Conhecimento (Dados I)

Tipos de Dados, Coleta de Dados e Introdução ao NumPy

Prof. João Vítor Rodrigues de Vasconcelos

Engenharia de Computação / Análise e Desenvolvimento de Sistemas
joaovasconcelos@univicosa.com.br

ADS308

Objetivos da Aula

- **Compreender a Natureza dos Dados:** Diferenciar dados estruturados, não estruturados e semi-estruturados.
- **Explorar a Coleta:** Entender como extraímos dados do mundo real para alimentar nossos modelos de IA.
- **Identificar Gargalos:** Compreender as limitações do Python nativo (listas) para grandes volumes de dados.
- **Introdução ao NumPy:** Conhecer a biblioteca base para computação científica e vetorização em Python.

A Base do Machine Learning

O Combustível da Inteligência Artificial

Diferente da programação clássica baseada em regras (como a busca A*), os modelos de Machine Learning aprendem **padrões a partir de exemplos**.

- Se o algoritmo é o motor, os dados são a gasolina.
- **Lixo entra, Lixo sai (GIGO):** Um modelo complexo treinado com dados ruins produzirá predições ruins.
- A maior parte do tempo de um Engenheiro de IA é gasta **coletando e preparando** dados.

Tipos de Dados: Estruturados

Definição

Dados altamente organizados, com esquema rígido, formatados em linhas e colunas. Facilmente armazenáveis em Bancos de Dados Relacionais (SGBDs).

- **Características:** Tipos definidos (Int, Float, Date, Varchar).
- **Exemplos:** Planilhas de Excel, arquivos CSV, tabelas SQL.
- **Uso em IA:** Previsão de vendas, análise de risco de crédito, detecção de fraude bancária.

Tipos de Dados: Não Estruturados

Definição

Informações que não possuem um modelo de dados predefinido. Representam cerca de 80% de todos os dados gerados atualmente no mundo.

- **Características:** Difíceis de processar por meios tradicionais. Precisam de algoritmos complexos para extrair significado.
- **Exemplos:** Imagens, vídeos, áudios, textos livres (e-mails, tweets).
- **Uso em IA:** Visão Computacional (YOLO), Processamento de Linguagem Natural (ChatGPT), Reconhecimento de Voz.

Tipos de Dados: Semi-estruturados

O Meio-Termo

Não possuem esquema rígido tabular, mas contêm marcadores, tags ou chaves que separam os elementos semânticos.

- **JSON (JavaScript Object Notation):** Padrão absoluto para comunicação entre sistemas web hoje. Muito similar aos *Dicionários* do Python.
- **XML / HTML:** Baseado em tags.
- **Uso em IA:** Geralmente é a ponte de coleta. Extraímos dados semi-estruturados de uma API e os convertemos em estruturados para treinar o modelo.

Coleta de Dados: Onde encontrá-los?

Na vida real, o Cientista/Engenheiro de Dados precisa buscar ativamente a informação.

- **Bancos de Dados Internos:** Consultas SQL diretas nos sistemas da empresa.
- **Datasets Públicos:** Repositórios como Kaggle, Portal de Dados Abertos do Governo, UCI Machine Learning Repository.
- **Sensores / IoT:** Coleta em tempo real de equipamentos industriais, termômetros, GPS.

Coleta de Dados: APIs e Web Scraping

Quando os dados pertencem a terceiros, usamos técnicas de extração:

APIs (Application Programming Interfaces)

Comunicação oficial e estruturada. Você pede um dado (ex: clima atual) e o servidor devolve um JSON organizado.

Web Scraping (Raspagem de Dados)

Comunicação não oficial. Usado quando não há API. O script em Python acessa uma página web, lê o código HTML e extrai o texto "à força"(ex: monitorar preços em e-commerces).

O Limite do Python Nativo

No primeiro laboratório, revisamos **Listas**. Elas são incrivelmente flexíveis:
`lista = [10, "texto", True, 3.14]`

Por que isso é um problema para Big Data e IA?

- **Memória Fragmentada:** As listas do Python guardam ponteiros espalhados na memória, não os dados contíguos.
- **Lentidão em Laços (Loops):** Fazer um laço `for` para multiplicar 10 milhões de números em uma lista leva tempo demais em Python.
- Para treinar IAs, precisamos de processamento matemático na velocidade da linguagem C.

Introdução ao NumPy

O que é o NumPy?

NumPy (Numerical Python) é a biblioteca base de todo o ecossistema de Ciência de Dados no Python (Pandas, Scikit-Learn e TensorFlow dependem dele).

- **O segredo:** Ele introduz o objeto `ndarray` (Array N-Dimensional).
- Tipagem estrita: Um array NumPy só aceita elementos do **mesmo tipo** (ex: só inteiros ou só floats).
- Alocação contígua em memória: Operações até 50x mais rápidas que listas nativas.

Matrizes e Dimensões

Modelos de IA enxergam dados como matrizes matemáticas.

- **1D (Vetor):** Uma linha ou coluna de dados. Ex: Uma série temporal de temperaturas.
- **2D (Matriz):** Linhas e colunas. Ex: Uma planilha tradicional ou uma imagem em escala de cinza.
- **3D (Tensor):** Múltiplas matrizes empilhadas. Ex: Uma imagem colorida (Largura $\times$ Altura $\times$ 3 canais de cor RGB).

NumPy na Prática: Criação e Inspeção

Trabalhando com ndarrays

```
import numpy as np

# Criando um array a partir de uma lista
lista_idades = [25, 30, 45, 22]
idades = np.array(lista_idades)

# Inspecionando a estrutura
print(idades.shape)  # Saída: (4,) -> 4 elementos, 1 dimensão
print(idades.dtype)  # Saída: int64 -> Tipo de dado uniforme

# Matriz 2D (Tabela)
matriz = np.array([[1, 2, 3], [4, 5, 6]])
print(matriz.shape)  # Saída: (2, 3) -> 2 linhas, 3 colunas
```

NumPy na Prática: A Mágica da Vetorização

A maior vantagem do NumPy é abolir o laço `for` para cálculos matemáticos.

Operação Vetorizada vs Loop

```
import numpy as np

# Vetor com salários em Reais
salarios_brl = np.array([3000, 4500, 5000, 8000])

# Converter para Dólar (Cotação = 5.0)
# COM LISTA NATIVA: Precisaria de um loop 'for'
# COM NUMPY: A operação é aplicada elemento a elemento
salarios_usd = salarios_brl / 5.0

print(salarios_usd)
# Saída: [ 600.  900. 1000. 1600.]
```

Conexão com o Mercado de Trabalho

Por que isso importa na vida real?

Nenhuma empresa contrata um Engenheiro de Computação apenas para "rodar algoritmos prontos". O valor real está em transformar **dados caóticos em dados estruturados**.

- Entender os tipos de dados dita qual banco de dados usar (SQL para estruturados, NoSQL para semi-estruturados).
- Saber fazer requisições em APIs e manipular JSON é tarefa diária na integração de microsserviços.
- O NumPy é a base invisível sob o qual os algoritmos do *Scikit-Learn* rodam nos servidores de produção.

Dúvidas?

Muito obrigado pela atenção!