Regressão Linear (O início de tudo)

Predizendo valores contínuos e o Método dos Mínimos Quadrados

Prof. João Vítor Rodrigues de Vasconcelos

Engenharia de Computação / Análise e Desenvolvimento de Sistemas
joaovasconcelos@univicosa.com.br

ADS308

Objetivos da Aula

- Compreender o conceito fundamental de Regressão em Machine Learning.
- Diferenciar problemas de regressão de problemas de classificação.
- Entender a formulação matemática da Regressão Linear Simples e Múltipla.
- Internalizar a intuição por trás do Método dos Mínimos Quadrados (OLS).
- Aprender as principais métricas de avaliação (R^2, MAE, RMSE).
- Visualizar a implementação prática utilizando Python e Scikit-Learn.

Onde estamos no Universo de Machine Learning?

Aprendizado Supervisionado

A Regressão Linear é um dos algoritmos mais clássicos e fundamentais do **Aprendizado Supervisionado**. Nele, fornecemos ao modelo dados históricos que já contêm a resposta correta (rótulos).

- **Classificação:** Prediz uma categoria ou classe discreta (ex: Spam ou Não Spam).
- **Regressão:** Prediz um valor numérico contínuo (ex: Preço de uma casa, Temperatura).

O que é Regressão?

- Historicamente, o termo foi cunhado por Francis Galton (séc. XIX) ao estudar a altura de pais e filhos.
- Ele observou uma "regressão à média": pais muito altos tendiam a ter filhos um pouco mais baixos, e vice-versa.
- Em Ciência de Dados moderna, **Regressão** é sinônimo de **estimar a relação** entre variáveis e predizer um alvo contínuo.

Variáveis Contínuas vs. Categóricas

Por que o tipo de dado importa?

O algoritmo que você escolhe depende da natureza do que você quer prever.

- **Contínuas (Regressão):** Podem assumir infinitos valores em um intervalo. Exemplos: Faturamento de vendas em reais (R$ 10.540,32), idade (34,5 anos), tempo de execução de um software (1.2s).
- **Categóricas (Classificação):** Assumem valores discretos. Exemplos: Nível de severidade de um bug (Baixo, Médio, Alto), detecção de fraude (Sim, Não).

Analogia do Mundo Real: Preço de Imóveis

- Imagine que você quer comprar um apartamento em Viçosa.
- Como você estima o preço justo?
- Intuitivamente, você considera o **tamanho do imóvel** (m^2).
- Quanto maior a área, maior o preço. Existe uma *correlação linear* (ou próxima disso).
- A Regressão Linear tenta encontrar a "régua"matemática que melhor traduz essa intuição.

Formalização do Problema

Terminologia de Machine Learning

Precisamos de um vocabulário comum para modelar o problema.

- X (Maiúsculo): Matriz de **Features** (variáveis independentes, preditores). Ex: Tamanho em m^2, número de quartos.
- y (Minúsculo): Vetor **Target** (variável dependente, alvo). Ex: Preço do imóvel.
- **Objetivo:** Encontrar uma função $f(X)$ tal que $f(X) \approx y$.

Revisitando a Geometria Analítica

- Lembra do Ensino Médio? A equação de uma reta é dada por:

$$y = ax + b$$

- Onde:
  - y: Variável dependente.
  - x: Variável independente.
  - a: Coeficiente angular (inclinação da reta).
  - b: Coeficiente linear (onde a reta cruza o eixo y).

A Equação da Regressão Linear Simples

A Roupagem Estatística

Em Data Science, usamos uma notação ligeiramente diferente para a mesma reta.

$$\hat{y} = \beta_0 + \beta_1 x_1$$

- $\hat{y}$ (y-chapéu): É o valor **predito** pelo nosso modelo.
- β_0: Intercepto (equivalente ao b). Valor base quando $x = 0$.
- β_1: Coeficiente da feature (peso da variável x_1).
- x_1: A feature de entrada.

Regressão Linear Múltipla

- No mundo real, um imóvel não depende só da área. Depende do número de quartos, vagas na garagem, distância do centro, etc.
- Expandimos a equação para múltiplas dimensões:

Modelo Multivariado

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + ... + \beta_n x_n$$

- Onde n é o número total de features (colunas no seu dataset).
- O modelo deixa de ser uma reta em 2D e passa a ser um **hiperplano** em N-dimensões.

A Busca pela "Melhor Reta"

- Se plotarmos um gráfico de dispersão (scatter plot) com Área no eixo X e Preço no eixo y, veremos uma nuvem de pontos.
- Podemos desenhar infinitas retas cruzando essa nuvem.
- **A pergunta de um milhão de dólares:** Qual é a *melhor* reta?
- Como a máquina "aprende"os valores de β_0 e β_1?

O Conceito de Erro (Resíduo)

Resíduo (e)

É a diferença entre o valor real (y) e o valor que o modelo previu ($\hat{y}$).

$$e_i = y_i - \hat{y}_i$$

- Se a previsão for perfeita, o erro é zero.
- Em qualquer problema real, as previsões terão algum erro.
- A "melhor reta"é aquela que **minimiza o erro total** para todos os pontos do dataset.

Por que elevar o erro ao quadrado?

- Se somarmos os erros simples $(y - \hat{y})$, erros positivos (pontos acima da reta) vão cancelar erros negativos (pontos abaixo da reta).
- Para resolver isso, poderíamos usar o módulo $|y - \hat{y}|$.
- No entanto, matematicamente, a função quadrática $(y - \hat{y})^2$ é mais vantajosa:
  - Transforma todos os erros em números positivos.
  - **Penaliza severamente erros maiores** (um erro de 2 vira 4, mas um erro de 10 vira 100).
  - É uma função derivável (essencial para encontrar o ponto mínimo em cálculo).

A Função de Custo: MSE

Mean Squared Error (Erro Quadrático Médio)

A função de custo avalia o quão ruim o nosso modelo é. Queremos que ela seja a menor possível.

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

- O aprendizado de máquina nada mais é do que um problema de **otimização**: encontrar os parâmetros (β) que levam o MSE ao seu valor mínimo global.

O Método dos Mínimos Quadrados (OLS)

- OLS (*Ordinary Least Squares*) é o método clássico para encontrar os parâmetros ótimos da regressão linear.
- A ideia intuitiva é exatamente esta: "Encontre os coeficientes que resultem na **menor soma dos quadrados** das distâncias entre os pontos reais e a reta".
- OScikit-Learn, no fundo, está resolvendo esse problema de otimização quando chamamos `model.fit()`.

Mínimos Quadrados: Solução Analítica

- Diferente de algoritmos mais complexos como Redes Neurais que exigem aproximação numérica (Gradient Descent), a Regressão Linear por OLS possui uma **solução fechada** (matemática exata).

A Equação Normal

Através de álgebra linear, os pesos ótimos $\boldsymbol{\beta}$ podem ser calculados diretamente:

$$\boldsymbol{\beta} = (\mathrm{X}^T\mathrm{X})^{-1}\mathrm{X}^T\mathrm{y}$$

- Isso significa que treinar uma regressão linear em bases pequenas é extremamente rápido do ponto de vista computacional.

Premissas da Regressão Linear

Cuidado com a "Caixa Preta"

Não basta jogar dados no Scikit-Learn. A estatística por trás do modelo exige que algumas condições sejam válidas para que as previsões sejam confiáveis.

- **Linearidade:** A relação entre X e y deve ser linear.
- **Independência:** As observações devem ser independentes umas das outras.
- **Ausência de Multicolinearidade:** Variáveis de entrada (X) não devem ser altamente correlacionadas entre si.
- **Homocedasticidade:** A variância dos resíduos deve ser constante.

Avaliando o Modelo: O R Quadrado (R^2)

- Como sabemos se nossa reta é realmente boa?
- A métrica mais famosa é o **Coeficiente de Determinação (R^2)**.

Interpretação do R^2

Ele mede a proporção da variância na variável dependente (y) que é explicada pelo nosso modelo. Varia de 0 a 1 (ou 0% a 100%).

- $R^2 = 1.0$: Modelo explica 100% da variação (previsões perfeitas).
- $R^2 = 0.0$: Modelo não explica nada (é tão bom quanto simplesmente chutar a média dos valores).

Outras Métricas de Avaliação

- O R^2 é ótimo para interpretar em porcentagem, mas muitas vezes precisamos saber o erro **nas unidades do problema** (ex: erro em Reais).

MAE (Mean Absolute Error)

Média absoluta dos erros. Mais interpretável e robusto a outliers. "Em média, nosso modelo erra por X unidades".

RMSE (Root Mean Squared Error)

A raiz quadrada do MSE. Penaliza erros grandes. Como tem a mesma unidade de y, é a métrica mais utilizada em competições de Machine Learning.

Python: Preparando o Ambiente

Usando Scikit-Learn

Vamos ver como a teoria se traduz em código na prática de Ciência de Dados.

```
import numpy as np
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression

# Criando dados fictícios de área (m2) e preço (R$)
X = np.array([45, 50, 60, 80, 100, 120]).reshape(-1, 1)
y = np.array([200, 220, 250, 310, 380, 450])

# Dividindo em treino e teste
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)
```

Python: Treinando o Modelo

A Magia do .fit()

É nesta linha que o Método dos Mínimos Quadrados é executado internamente.

```
# Instanciando o modelo
modelo = LinearRegression()

# Treinando (encontrando os Betas)
modelo.fit(X_train, y_train)

# Inspecionando os coeficientes
print("Intercepto (b0):", modelo.intercept_)
print("Coeficiente angular (b1):", modelo.coef_[0])
```

Python: Prevendo e Avaliando

Métricas na Prática

Uma vez treinado, fazemos previsões e medimos o erro.

```
from sklearn.metrics import r2_score, mean_squared_error

# Fazendo previsões com dados nunca vistos
y_pred = modelo.predict(X_test)

# Avaliando
print("R2 Score:", r2_score(y_test, y_pred))

# Calculando o RMSE
rmse = np.sqrt(mean_squared_error(y_test, y_pred))
print("RMSE:", rmse)
```

Limitações da Regressão Linear

- **Sensibilidade a Outliers:** Como o erro é elevado ao quadrado (Mínimos Quadrados), pontos fora da curva "puxam"a reta intensamente.
- **Restrição Linear:** Nem todo problema no mundo é linear. Se a relação entre área e preço for exponencial ou quadrática, uma reta terá um desempenho pífio (underfitting).
- Para relações complexas e não lineares, algoritmos como Árvores de Decisão, Random Forest ou Redes Neurais são mais adequados.

Conexão com o Mercado de Trabalho

Por que isso importa na vida real?

Se existem Redes Neurais, por que aprender Regressão Linear?

- **Baseline:** É sempre o primeiro modelo testado. Rápido, barato e serve de base comparativa.
- **Interpretabilidade:** Em finanças, saúde ou direito (onde a "explicabilidade"da IA é exigida por lei), a regressão linear permite dizer exatamente o impacto de cada variável no resultado analisando os coeficientes β.
- **Previsão de Demanda e Séries Temporais:** Usada exaustivamente no varejo para prever vendas, estoque e precificação dinâmica.

Dúvidas e Encerramento

Recapitulando

A Regressão Linear é a porta de entrada para o aprendizado de máquina contínuo. Entender o conceito matemático do Erro Quadrático molda o raciocínio necessário para arquiteturas mais avançadas de Deep Learning.

Perguntas?

E-mail: joaovasconcelos@univicosa.com.br