Análise Exploratória de Dados (EDA)

Estatística descritiva aplicada (média, mediana, desvio) e Correlação

Prof. João Vítor Rodrigues de Vasconcelos

Engenharia de Computação / Análise e Desenvolvimento de Sistemas
joaovasconcelos@univicosa.com.br

ADS308

Objetivos da Aula

O que aprenderemos hoje?

- Entender o conceito e a importância da Análise Exploratória de Dados (EDA).
- Dominar as medidas de tendência central: média e mediana.
- Compreender medidas de dispersão, com foco no desvio padrão.
- Explorar a relação entre variáveis numéricas através da correlação.
- Diferenciar matematicamente e logicamente correlação de causalidade.
- Aplicar esses conceitos utilizando a linguagem Python e a biblioteca Pandas.

Introdução à Análise Exploratória de Dados (EDA)

Definição

A Análise Exploratória de Dados (EDA) é uma abordagem para analisar conjuntos de dados resumindo suas características principais, frequentemente utilizando métodos visuais e estatísticos.

- Criada pelo estatístico John Tukey na década de 1970.
- É o primeiro passo prático após a coleta de dados.
- Foca na descoberta em vez da confirmação formal de hipóteses.

O Papel da EDA em Ciência de Dados

- **Entendimento do Negócio:** Traduzir dados brutos em insights preliminares.
- **Qualidade dos Dados:** Identificar valores ausentes (*missing values*) e inconsistências.
- **Detecção de Anomalias:** Encontrar *outliers* que podem distorcer os modelos de Machine Learning.
- **Seleção de Features:** Escolher quais variáveis (colunas) são mais relevantes para prever o nosso alvo (*target*).

Estatística Descritiva: O que é?

Conceito Chave

É o ramo da estatística que lida com a sumarização e descrição de conjuntos de dados. Ela transforma milhares de linhas de dados brutos em métricas simples e interpretáveis.

Divide-se principalmente em:

- **Medidas de Frequência:** Contagem, percentual.
- **Medidas de Tendência Central:** Média, Mediana, Moda.
- **Medidas de Dispersão:** Variância, Desvio Padrão, Amplitude.
- **Medidas de Posição:** Quartis, Decis, Percentis.

Revisão Rápida: Tipos de Variáveis

Para aplicar a estatística correta, precisamos saber o tipo de dado:

Qualitativas (Categóricas)

- **Nominal:** Sem ordem natural (Ex: Cor dos olhos, Estado Civil).
- **Ordinal:** Com ordem natural (Ex: Escolaridade, Classe Social).

Quantitativas (Numéricas)

- **Discreta:** Valores inteiros, contáveis (Ex: Número de filhos, Quantidade de cliques).
- **Contínua:** Valores reais, mensuráveis (Ex: Salário, Altura, Temperatura).

Medidas de Tendência Central

- O objetivo dessas medidas é encontrar um valor único que **represente o centro** da distribuição dos dados.
- É a resposta rápida para a pergunta: "Em geral, como se comportam esses dados?".

Hoje focaremos nas duas mais utilizadas em Machine Learning:

1. Média (Aritmética)
2. Mediana

Média: O Ponto de Equilíbrio

Definição Matemática

A média aritmética é a soma de todos os valores dividida pelo número total de observações.

Fórmula: $\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$

- **Vantagem:** Leva todos os valores em consideração. É excelente para dados que seguem uma distribuição normal (Curva de Sino).
- **Desvantagem:** É extremamente sensível a valores atípicos (*outliers*).

O Perigo da Média: A Analogia do Bar

Cenário

Imagine um bar com 10 engenheiros de software recém-formados. O salário de cada um gira em torno de R$ 5.000. A **média** salarial do bar é R$ 5.000.

O Outlier

De repente, Elon Musk entra no bar. O salário dele é na casa dos bilhões. Se calcularmos a nova média, o salário médio do bar passa a ser de **milhões de reais**.

Pergunta: Dizer que o salário médio no bar é de milhões representa a realidade daquelas pessoas? **Não!** É aqui que a média falha.

Média na Prática (Python Pandas)

```
import pandas as pd
import numpy as np

# Criando nosso DataFrame de salários no bar
salarios = [5000, 5200, 4900, 5100, 5000, 5300,
            4800, 5050, 4950, 5150, 20000000] # Elon Musk

df = pd.DataFrame(salarios, columns=["Salario"])

# Calculando a média
media_salarial = df["Salario"].mean()

print(f"A média salarial é: R$ {media_salarial:.2f}")
# Saída esperada: Um valor absurdamente alto e distorcido!
```

Mediana: O Valor Central

Definição

A mediana é o valor que divide um conjunto de dados **ordenado** exatamente ao meio. 50% dos dados estão abaixo dela, e 50% estão acima.

- **Vantagem principal:** É uma medida **robusta**. Ela praticamente ignora a existência de *outliers* extremos.

No exemplo do bar, mesmo com o Elon Musk, a mediana continuará sendo em torno de R$ 5.000, pois ela aponta para a "pessoa do meio"na fila de salários.

Média vs Mediana: Aplicações em Machine Learning

Imputação de Dados Ausentes

Em Ciência de Dados, frequentemente recebemos datasets com dados faltantes (NaN). Uma técnica comum é preencher esses buracos com a média ou mediana da coluna.

- **Quando usar a Média?** Quando a distribuição dos dados for simétrica (sem *outliers* graves). Ex: Altura de uma população, notas em uma prova escolar.
- **Quando usar a Mediana?** Quando os dados forem assimétricos (fortemente distorcidos). Ex: Preço de imóveis, Renda salarial, Tempo de permanência em um site.

Mediana na Prática (Python Pandas)

```
# Utilizando o mesmo DataFrame "df" do exemplo anterior

# Calculando a mediana
mediana_salarial = df["Salario"].median()

print(f"Média distorcida: R$ {df["Salario"].mean():.2f}")
print(f"Mediana robusta: R$ {mediana_salarial:.2f}")

# Preenchendo valores ausentes com a mediana (Exemplo ML)
# df["Salario"] = df["Salario"].fillna(df["Salario"].median())
```

Medidas de Dispersão: Entendendo a Variação

Apenas saber onde está o centro dos dados não é suficiente. Precisamos entender como os dados se espalham ao redor desse centro.

O Paradoxo do Clima

Duas cidades podem ter temperatura média anual de 20ºC.

- **Cidade A:** Varia de 18ºC a 22ºC o ano todo (Baixa dispersão).
- **Cidade B:** Varia de -5ºC no inverno a 45ºC no verão (Alta dispersão).

O preparo para morar na Cidade B é totalmente diferente, apesar da média ser igual!

Variância e Desvio Padrão

- **Variância (σ^2):** É a média dos quadrados das diferenças entre cada valor e a média.
  - *Problema:* A unidade de medida fica ao quadrado (ex: Reais ao quadrado, metros quadrados), dificultando a interpretação.
- **Desvio Padrão (σ):** É a raiz quadrada da variância.
  - *Solução:* Traz o valor numérico de volta para a **unidade original** dos dados.

Regra Geral

Baixo desvio padrão: Dados agrupados perto da média (consistentes).
Alto desvio padrão: Dados muito espalhados (alta volatilidade).

Analogia: Desvio Padrão = Risco

Em finanças e análise de risco para Machine Learning, o desvio padrão é sinônimo de **risco ou incerteza**.

- **Ativo X (Renda Fixa):** Rende em média 10% ao ano. Desvio Padrão de **1%**. (Seguro, sabemos que renderá entre 9% e 11%).
- **Ativo Y (Criptomoeda):** Rende em média 10% ao ano. Desvio Padrão de **40%**. (Arriscado, pode render +50% ou dar prejuízo de -30%).

Em Data Science, variáveis com desvio padrão próximo de zero (*Zero Variance*) geralmente são eliminadas, pois não oferecem poder preditivo ao modelo de IA.

Desvio Padrão na Prática (Python Pandas)

```
# Criando um dataset de duas cidades (temperaturas em 5 dias)
dados_clima = {
    "Cidade_A": [19, 20, 20, 21, 20],
    "Cidade_B": [-5, 10, 20, 30, 45]
}
df_clima = pd.DataFrame(dados_clima)

print("Médias de temperatura:")
print(df_clima.mean()) # Ambas terão média 20

print("\nDesvio Padrão (Volatilidade):")
print(df_clima.std())
# Cidade_A terá desvio muito baixo (ex: ~0.7)
# Cidade_B terá desvio muito alto (ex: ~19)
```

Alternativa Robusta: Quartis

Assim como a média sofre com *outliers*, o desvio padrão também sofre (pois usa a média na sua fórmula).

Quartis (Q1, Q2, Q3)

Dividem os dados ordenados em 4 partes iguais de 25% cada.

- **Q1 (25%):** 25% dos dados são menores que este valor.
- **Q2 (50%):** É a própria Mediana!
- **Q3 (75%):** 75% dos dados são menores que este valor.

A diferença entre Q3 e Q1 é o **Intervalo Interquartil (IQR)**. É a métrica de dispersão mais segura quando os dados estão "sujos".

Correlação entre Variáveis

Até agora, analisamos uma coluna por vez (Análise Univariada). E se quisermos saber a relação entre duas colunas (Análise Bivariada)?

O que é Correlação?

É uma medida estatística que indica o quão fortemente duas variáveis numéricas estão relacionadas linearmente. Se uma variável muda, como a outra se comporta?

- É expressa pelo coeficiente de correlação (r), que varia sempre de **-1 a 1**.

Tipos de Correlação (Valores de r)

- **Correlação Positiva ($r > 0$):** As variáveis caminham juntas. Se uma sobe, a outra sobe.
  - *Exemplo:* Anos de experiência x Salário.
- **Correlação Negativa ($r < 0$):** Variáveis inversamente proporcionais. Se uma sobe, a outra desce.
  - *Exemplo:* Preço de um produto x Quantidade vendida.
- **Correlação Nula ($r \approx 0$):** Não existe padrão linear claro entre as variáveis.
  - *Exemplo:* Número do sapato x QI da pessoa.

Métodos de Correlação: Pearson vs Spearman

Na Ciência de Dados, escolhemos o método com base na distribuição:

Correlação de Pearson (r)

- Mede relação estritamente **linear**.
- Assume que os dados não possuem *outliers* severos.
- É o padrão da maioria dos softwares.

Correlação de Spearman (ρ)

- Mede relação **monotônica** (tendência de subir/descer juntos, mesmo que não seja uma reta perfeita).
- Baseado no ranking (posição) dos dados.
- Muito mais **robusto a outliers**.

Calculando Correlação (Python Pandas)

```
import pandas as pd

dados_vendas = {
    "Investimento_Marketing": [1000, 2000, 3000, 4000],
    "Vendas": [150, 300, 450, 600],
    "Preco_Produto": [50, 45, 40, 35]
}
df_vendas = pd.DataFrame(dados_vendas)

# Correlação de Pearson (Padrão)
corr_pearson = df_vendas.corr()

# Correlação de Spearman
corr_spearman = df_vendas.corr(method="spearman")

# Investimento e Vendas terão correlação próxima de 1.0
# Preco e Vendas terão correlação negativa
```

O Grande Aviso: Correlação $\neq$ Causalidade

A Regra de Ouro

O fato de duas variáveis se moverem juntas **NÃO** significa que uma causa a outra.

O Paradoxo do Sorvete e do Tubarão:

- Dados mostram que: Semanas com maior venda de sorvete coincidem com semanas com mais ataques de tubarão na praia ($r = +0.85$).
- Conclusão errada: Comer sorvete atrai tubarões (ou proibir sorvete salva vidas).
- **Variável de Confusão (Oculta):** O Clima (Verão). No verão, mais pessoas tomam sorvete E mais pessoas entram no mar.

Matriz de Correlação e Heatmaps

Em *datasets* com dezenas ou centenas de colunas, calcular a correlação uma a uma é inviável.

- **Matriz de Correlação:** Uma tabela onde as linhas e colunas são as variáveis, e os cruzamentos mostram o valor de r. A diagonal principal é sempre 1 (a variável com ela mesma).
- **Heatmap (Mapa de Calor):** É a representação visual da Matriz. Usamos cores fortes (ex: Vermelho Escuro e Azul Escuro) para destacar correlações fortes, facilitando a análise visual rápida.

Plotando um Heatmap (Seaborn)

```
import seaborn as sns
import matplotlib.pyplot as plt

# Usando o df_vendas do exemplo anterior
matriz_corr = df_vendas.corr()

# Configurando o tamanho do gráfico
plt.figure(figsize=(8, 6))

# Plotando com Seaborn
sns.heatmap(matriz_corr, annot=True,
            cmap="coolwarm", vmin=-1, vmax=1)

plt.title("Mapa de Calor das Correlações")
plt.show()
```

Correlação no Machine Learning: Feature Selection

Como usamos isso para melhorar nossos algoritmos de IA?

Evitando a Multicolinearidade

Se duas colunas de características (*features*) têm uma correlação altíssima entre si (ex: > 0.90), elas contêm essencialmente a **mesma informação**.

- Exemplo: Coluna "Ano de Nascimento"e coluna "Idade".
- **Ação:** Mantemos apenas uma delas e deletamos a outra.
- **Benefícios:** Reduz a complexidade computacional, previne *overfitting* e deixa o modelo de IA mais rápido e interpretável.

Conexão com o Mercado de Trabalho

Por que isso importa na vida real?

Iniciantes focam apenas em "rodar algoritmos", mas o mercado valoriza quem sabe **entender os dados**.

- **A Realidade do Tempo:** 70% a 80% do tempo de um Cientista/Engenheiro de Dados é gasto em EDA e preparação de dados.
- **Comunicação Executiva:** Você não vai explicar *Gradient Descent* para o CEO da empresa. Você vai apresentar **médias, medianas e correlações** para justificar decisões de negócios.
- **Garbage in, Garbage out:** Modelos complexos alimentados com dados não explorados e cheios de *outliers* performarão pior que modelos simples com dados bem tratados.

Dúvidas?

Muito obrigado pela atenção. Excelentes estudos a todos!