Conceitos de Aprendizado de Máquina

Supervisionado vs Não Supervisionado vs Reforço
O que é Treino, Teste e Validação

Prof. João Vítor Rodrigues de Vasconcelos

Engenharia de Computação / Análise e Desenvolvimento de Sistemas
joaovasconcelos@univicosa.com.br

ADS308

Objetivos da Aula

O que vamos aprender hoje?

Compreender os fundamentos teóricos e práticos que baseiam o Aprendizado de Máquina (Machine Learning).

- Diferenciar os três principais paradigmas de aprendizado.
- Entender a intuição matemática e algorítmica por trás de cada paradigma.
- Explorar casos de uso reais (Séries temporais, Visão Computacional, Jogos).
- Compreender a importância e a metodologia da divisão de dados: Treino, Teste e Validação.

O que é Aprendizado de Máquina?

Definição Clássica (Arthur Samuel, 1959)

Campo de estudo que dá aos computadores a habilidade de aprender sem serem explicitamente programados.

- Em vez de escrevermos um conjunto rígido de regras (*if/else*), fornecemos dados.
- O algoritmo identifica padrões matemáticos e estatísticos nestes dados.
- A performance melhora com a experiência (quantidade e qualidade dos dados).

O Paradigma Clássico vs Aprendizado de Máquina

Programação Tradicional

Dados + **Regras** $\rightarrow$ *Computador* $\rightarrow$ **Respostas**

- Exemplo: Calcular o salário de um funcionário baseado em horas trabalhadas. A fórmula é conhecida.

Aprendizado de Máquina

Dados + **Respostas** $\rightarrow$ *Computador* $\rightarrow$ **Regras**

- Exemplo: Fornecemos fotos de cães e gatos (Dados) com suas respectivas etiquetas (Respostas). O modelo descobre o que define cada animal (Regras).

Os Três Pilares do Aprendizado de Máquina

Como as máquinas aprendem? A abordagem depende da disponibilidade de dados e do objetivo do problema.

- **1. Aprendizado Supervisionado:** Aprender com um professor (dados rotulados).
- **2. Aprendizado Não Supervisionado:** Aprender sozinho, buscando estrutura oculta (dados não rotulados).
- **3. Aprendizado por Reforço:** Aprender interagindo com o ambiente (tentativa, erro e recompensas).

1. Aprendizado Supervisionado

Conceito

O algoritmo recebe um conjunto de dados onde as respostas corretas (*labels* ou rótulos) já são conhecidas. O objetivo é mapear a entrada (X) para a saída (y).

- É o paradigma mais comum na indústria atual.
- Pode ser dividido em duas grandes categorias de problemas:
  - Classificação.
  - Regressão.

Supervisionado: Classificação

O que é?

A variável de saída (alvo) é categórica. O modelo deve prever a qual classe um dado pertence.

- **Classes Discretas:** Sim/Não, Gato/Cachorro, Doente/Saudável.
- **Algoritmos Comuns:** Árvores de Decisão (Decision Trees), Regressão Logística, SVM.
- **Analogia:** Separar frutas em caixas diferentes com base em cor e textura.

Supervisionado: Regressão

O que é?

A variável de saída é contínua e numérica. O modelo tenta prever um valor exato dentro de um espectro.

- **Saídas Contínuas:** Preços, Temperaturas, Quantidades.
- **Algoritmos Comuns:** Regressão Linear, Random Forest Regressor, Redes Neurais.
- **Analogia:** Tentar adivinhar o peso exato de uma pessoa apenas olhando para sua altura e idade.

Exemplo Prático: Visão Computacional

Detecção de Objetos (Classificação + Localização)

Imagine um modelo como o YOLO (You Only Look Once) operando em um vídeo em tempo real.

- **Dados de Entrada (X):** Milhares de imagens de trânsito.
- **Rótulos (y):** Caixas delimitadoras (*bounding boxes*) marcando "Carro", "Pedestre", "Semáforo".
- O modelo *aprende* os padrões de pixels que formam um carro para detectá-los em novas imagens.

Exemplo Prático: Séries Temporais

Previsão de Produção Agrícola (Regressão)

Trabalhando com um dataset de 45.000 linhas com indicadores mensais de fazendas.

- **Dados de Entrada (X):** Precipitação, temperatura, fertilizante usado, tipo de solo ao longo do tempo.
- **Rótulo Contínuo (y):** Toneladas de soja colhidas no final da safra.
- O modelo entende como o clima passado afeta o rendimento futuro.

Código Python: Scikit-Learn (Supervisionado)

Exemplo de Treinamento e Previsão

```
from sklearn.tree import DecisionTreeClassifier

# Instanciando o modelo
modelo = DecisionTreeClassifier()

# O modelo APRENDE a relação entre dados e rótulos
modelo.fit(X_treino, y_treino)

# O modelo PREVÊ novas saídas para dados inéditos
previsoes = modelo.predict(X_novos)
```

2. Aprendizado Não Supervisionado

Conceito

O algoritmo recebe dados brutos, **sem nenhum rótulo** ou resposta correta. O objetivo é encontrar padrões, agrupamentos ou estruturas ocultas nos dados por conta própria.

- O modelo age como um explorador.
- Principais abordagens:
  - Clusterização (Agrupamento).
  - Redução de Dimensionalidade.

Não Supervisionado: Clusterização

O que é?

Agrupar dados semelhantes em "clusters"ou conjuntos.

- O algoritmo mede a distância ou similaridade entre as amostras matemáticas.
- **Algoritmos Comuns:** K-Means, DBSCAN, Hierarchical Clustering.
- **Analogia:** Você chega a um país estrangeiro e agrupa as moedas que encontra por cor e tamanho, mesmo sem saber o valor delas.

Não Supervisionado: Redução de Dimensionalidade

O que é?

Reduzir a quantidade de variáveis (colunas) de um dataset gigante, mantendo a maior parte da informação relevante.

- Essencial para datasets complexos e para visualização de dados.
- Evita a "Maldição da Dimensionalidade".
- **Algoritmos Comuns:** PCA (Principal Component Analysis), t-SNE.

Exemplo Prático: Segmentação

Sistemas de Recomendação e Marketing

Entender perfis sem categorização prévia.

- Um e-commerce tem milhões de transações, mas não tem rótulos definindo "tipos de clientes".
- Aplicando Clusterização, o modelo descobre:
  - Grupo A: Compram eletrônicos à noite.
  - Grupo B: Compram itens de pet shop (ração, remédios) de forma recorrente.
- Permite marketing direcionado.

Código Python: K-Means (Não Supervisionado)

Exemplo de Clusterização

Note que não passamos o y no fit.

```
from sklearn.cluster import KMeans

# Queremos encontrar 3 grupos distintos nos dados
modelo_kmeans = KMeans(n_clusters=3)

# O modelo APRENDE os agrupamentos apenas olhando o X
modelo_kmeans.fit(X_dados_brutos)

# Atribui cada linha a um dos 3 clusters encontrados
grupos = modelo_kmeans.predict(X_dados_brutos)
```

3. Aprendizado por Reforço

Conceito

Inspirado na psicologia comportamental. Um **agente** aprende a tomar decisões executando **ações** em um **ambiente** para maximizar uma **recompensa** cumulativa.

- Não há dados pré-existentes; os dados são gerados durante a interação.
- Baseia-se em tentativa e erro (Exploração vs. Explotação).

Os Componentes do Reforço

Vocabulário Essencial

- **Agente:** O "cérebro"ou algoritmo que toma as decisões.
- **Ambiente:** O mundo com o qual o agente interage.
- **Estado:** A situação atual do agente no ambiente.
- **Ação:** O que o agente decide fazer.
- **Recompensa:** O feedback (positivo ou negativo) recebido após a ação.

Exemplo Prático: Robótica e Jogos

Aplicações no Mundo Real

Onde o Reforço brilha de forma absoluta.

- **Robótica:** Ensinar a cinemática de um braço robótico. O agente ganha pontos se a garra se aproxima do objeto e perde pontos se bater na mesa.
- **E-sports (Dota 2, StarCraft):** O projeto OpenAI Five aprendeu a jogar Dota 2 jogando milhões de partidas contra si mesmo, maximizando a recompensa (destruir o "Ancient"inimigo).

Resumo dos Paradigmas

Qual utilizar?

- Tenho dados com os resultados históricos? $\rightarrow$ **Supervisionado**.
- Tenho muitos dados, não sei o que significam e quero achar padrões? $\rightarrow$ **Não Supervisionado**.
- Tenho um ambiente interativo ou simulador onde posso testar ações iterativas? $\rightarrow$ **Reforço**.

A Avaliação de Modelos: A Importância dos Dados

O Ciclo de ML não acaba no Treinamento

Treinar um modelo é fácil. O difícil é garantir que ele funcione na vida real (Generalização).

- Se o modelo apenas memorizar os dados que viu, ele falhará miseravelmente quando vir dados novos.
- Esse problema fatal é chamado de **Overfitting** (Sobreajuste).
- Para evitar isso, precisamos dividir nosso Dataset original.

Divisão de Dados: A Regra de Ouro

A Metodologia Clássica

Nunca, em hipótese alguma, avalie um modelo com os mesmos dados que você usou para treiná-lo.

- Analogia: Um professor aplica uma prova com as exatas mesmas questões da lista de exercícios. O aluno tirou 10 porque entendeu a matéria ou porque decorou o gabarito?
- Solução: Divisão em Treino, Validação e Teste (ex: 70% / 15% / 15%).

O Conjunto de Treino (Train Set)

O Material de Estudo

É a maior fatia dos nossos dados (geralmente entre 70% a 80%).

- É o conjunto exposto ao algoritmo durante a fase de aprendizado.
- O modelo usa esses dados para ajustar seus pesos matemáticos, calcular o erro e se corrigir.
- Representa a "lista de exercícios resolvidos".

O Conjunto de Validação (Validation Set)

O Simulado

Uma fatia intermediária dos dados (geralmente 10% a 15%).

- Usado **durante** o ciclo de desenvolvimento, mas o modelo não treina diretamente neles.
- Serve para que o Engenheiro/Cientista de Dados possa ajustar os hiperparâmetros (configurações do algoritmo).
- Ajuda a detectar se o modelo está começando a sofrer de Overfitting antes de fechar a versão final.

O Conjunto de Teste (Test Set)

A Prova Final

A última fatia dos dados (geralmente 10% a 20%). Trancada a sete chaves.

- Só é utilizado **uma única vez**, quando o modelo já está totalmente pronto e ajustado.
- Simula o mundo real. O modelo nunca viu esses dados antes.
- A métrica extraída daqui é a que será reportada para o cliente ou para a empresa como a "acurácia real"da Inteligência Artificial.

Código Python: Divisão de Dados

Scikit-Learn: train_test_split

Exemplo dividindo em Treino (80%) e Teste (20%).

```
from sklearn.model_selection import train_test_split

# Dividindo os arrays de Features (X) e Labels (y)
X_treino, X_teste, y_treino, y_teste = train_test_split(
    X,
    y,
    test_size=0.20, # 20% para teste
    random_state=42 # Para reprodutibilidade
)
```

Conexão com o Mercado de Trabalho

Por que isso importa na vida real?

Nenhuma empresa paga por um modelo que só funciona no seu computador.

- **Entender os paradigmas** define se um projeto vai falhar no primeiro mês ou gerar lucro (saber escolher a ferramenta certa).
- **Vazamento de Dados (Data Leakage):** Misturar teste e treino é o erro número 1 de desenvolvedores juniores, gerando prejuízos milionários ao prometer métricas ilusórias.
- O mercado exige profissionais que entendam a **confiabilidade** do modelo. Ferramentas de XAI (Explainable AI) como SHAP dependem dessa robustez.

Próximos Passos

O que veremos no próximo laboratório prático?

Vamos colocar as mãos no código e sair da teoria.

- Configuração de ambiente Python (Jupyter / Colab).
- Carga e manipulação de Datasets com `Pandas`.
- Treinamento de uma Árvore de Decisão do zero.
- Avaliação prática do nosso modelo usando os conjuntos de Teste e Validação.

Dúvidas?

Muito obrigado pela atenção!

Prof. João Vítor Rodrigues de Vasconcelos
joaovasconcelos@univicosa.com.br