Laboratório Prático: Tratamento de Dados

Limpando e Preparando o Dataset de Imóveis

Prof. João Vítor Rodrigues de Vasconcelos

Engenharia de Computação / Análise e Desenvolvimento de Sistemas
joaovasconcelos@univicosa.com.br

ADS308

O Desafio do Laboratório

Cenário Real

Façam o download da base de dados `dataset_imoveis_sujo.csv` através deste link do Google Drive. Ela contém informações de 250 imóveis. O objetivo é prever o preço das casas, mas os dados vieram de um sistema legado cheio de falhas.

- **Problema 1:** Sensores falharam e há valores nulos (NaN) nas colunas de *Área* e *Quartos*.
- **Problema 2:** Erros de digitação inseriram preços absurdos (acima de 8 milhões de reais) para casas comuns.
- **Problema 3:** As grandezas estão desproporcionais (Quartos variam de 1 a 5, Áreas passam de 100).

Roteiro da Prática (Missões)

O que deve ser feito?

Vocês deverão criar um script em Python (Jupyter Notebook ou Colab) para executar o pipeline de engenharia de dados.

1. **Carregamento:** Ler o arquivo CSV e exibir a contagem inicial de nulos (`isnull().sum()`).
2. **Imputação:** Preencher os nulos da coluna *Area_m2* com a **média** e os nulos de *Quartos* com a **mediana**.
3. **Filtragem de Outliers:** Calcular o IQR (Intervalo Interquartil) da coluna *Preco_BRL* e remover as linhas com valores discrepantes.
4. **Escalonamento:** Aplicar o `MinMaxScaler` na coluna *Area_m2* para que os valores fiquem entre 0 e 1.

Código Inicial (Starter Code)

Ponto de Partida

Abram suas IDEs e comecem importando as bibliotecas necessárias e carregando o dataset fornecido.

```
import pandas as pd
import numpy as np
from sklearn.preprocessing import MinMaxScaler

# 1. Carregando os dados
df = pd.read_csv("dataset_imoveis_sujo.csv")

# Visualizando as primeiras linhas e o estrago
print(df.head())
print("\nTotal de Nulos:")
print(df.isnull().sum())
```

Dicas para a Missão 2 e 3

- **Para preencher NaNs:** Lembrem-se do método `fillna()`. Vocês podem calcular a média antes e passar como argumento.

```
# Exemplo genérico:
media_coluna = df["Nome_da_Coluna"].mean()
df["Nome_da_Coluna"] = df["Nome_da_Coluna"].fillna(media_coluna)
```

- **Para remover os Outliers (IQR):** Lembrem-se da fórmula matemática.
  - $Q1 = \text{quantile}(0.25)$
  - $Q3 = \text{quantile}(0.75)$
  - $IQR = Q3 - Q1$
  - $Limite_{Superior} = Q3 + 1.5 \times IQR$

  Usem máscaras booleanas para manter apenas quem for **menor ou igual** ao Limite Superior.

Dica para a Missão 4 (Normalização)

Atenção ao Formato dos Dados!

O `scikit-learn` é rigoroso com o formato (shape) dos dados que ele recebe para treinar ou transformar.

- Quando forem usar o `fit_transform()` do `MinMaxScaler`, o Pandas precisa enviar um DataFrame (matriz 2D), e não uma Series (vetor 1D).
- **Erro Comum:** Passar apenas um colchete.
  - `df['Area_m2']` → Retorna Series (Vai dar erro!)
  - `df[['Area_m2']]` → Retorna DataFrame (Correto!)

Mãos à obra! O professor estará circulando para tirar dúvidas.